SMC per un masked diffusion language model

Nota matematica minimale

1 Modello base

La generazione del masked diffusion model e' una catena di Markov

$$X_0 = [\text{MASK}]^L, \qquad X_t \sim K_t(\cdot \mid X_{t-1}), \quad t = 1, \dots, T.$$

La probabilita' congiunta di una traiettoria e'

$$P_0(x_{0:T}) = \prod_{t=1}^{T} K_t(x_t \mid x_{t-1}).$$

In un singolo passo, i token ancora mascherati possono essere campionati condizionatamente in parallelo. Questo non rende indipendenti i token della completion: ogni distribuzione dipende dall'intero stato precedente. La probabilita' terminale e'

$$p_0(x_T) = \sum_{x_1, \dots, x_{T-1}} P_0(x_{0:T}),$$

ma l'algoritmo non deve calcolare esplicitamente questa somma.

2 Distribuzione tilted

Sia $R(x_T)$ il reward terminale e sia $\lambda \geq 0$. Vogliamo campionare dalla distribuzione

$$\pi_\lambda(x_T) = \frac{p_0(x_T) e^{\lambda R(x_T)}}{Z_\lambda}, \qquad Z_\lambda = \mathbb{E}_{p_0}[e^{\lambda R(X_T)}].$$

Scegliamo checkpoint $0 = t_0 < t_1 < \cdots < t_m = T$. Per $k < m$, completiamo deterministicamente lo stato parziale X_{t_k} tramite argmax e calcoliamo un reward provvisorio $R_k(X_{t_k})$. Al terminale usiamo la completion realmente campionata:

$$R_m(X_T) = R(X_T).$$

Definiamo il log-potenziale

$$\Phi_k(X_{t_k}) = \beta_k R_k(X_{t_k}), \qquad \beta_0 = 0, \quad \beta_m = \lambda.$$

3 Peso SMC e resampling

Ogni particella viene propagata con lo stesso kernel K_t del modello base. Al checkpoint k, il suo peso viene moltiplicato per

$$G_k = \exp\big(\Phi_k(X_{t_k}) - \Phi_{k-1}(X_{t_{k-1}})\big).$$

Equivalentemente,

$$\log w_k = \log w_{k-1} + \Phi_k(X_{t_k}) - \Phi_{k-1}(X_{t_{k-1}}),$$

seguito dalla normalizzazione dei pesi.

Se l'ESS

$$\mathrm{ESS} = \frac{1}{\sum_i (W_k^{(i)})^2}$$

scende sotto la soglia, si estraggono i genitori con probabilita' $W_k^{(i)}$ e si riportano i pesi a $1/N$. L'informazione dei pesi precedenti rimane nella molteplicita' dei discendenti.

Il prodotto dei potenziali lungo ogni genealogia telescopa:

$$\prod_{k=1}^{m} G_k = \exp(\Phi_m(X_T) - \Phi_0(X_0)) = e^{\lambda R(X_T)}.$$

Di conseguenza, i reward provvisori influenzano il resampling e quindi l'efficienza, ma non modificano il target terminale.

4 Perche' non serve la joint probability della completion

In generale, un peso di importance sampling contiene il rapporto tra il kernel del target K_t e il kernel di proposta Q_t. Qui la propagazione non viene modificata:

$$Q_t = K_t \qquad \Longrightarrow \qquad \frac{K_t}{Q_t} = 1.$$

Le probabilita' del masked diffusion model sono quindi gia' incluse nel campionamento della traiettoria e si cancellano nel rapporto. Rimane soltanto il rapporto tra i potenziali G_k.

Questa giustificazione richiede che la propagazione resti esattamente quella del modello base. Se si modificassero logits, temperatura o kernel di demasking, sarebbe necessario includere il corrispondente rapporto K_t/Q_t nei pesi.

5 Stima dell'evento raro

Sia E l'evento raro. Dalla distribuzione tilted vale l'identita'

$$p_0(E) = \frac{\mathbb{E}_{\pi_\lambda}\left[e^{-\lambda R(X)} \mathbf{1}_E(X)\right]}{\mathbb{E}_{\pi_\lambda}\left[e^{-\lambda R(X)}\right]}.$$

Se (X_i, W_i) e' la popolazione SMC terminale, definiamo

$$\widetilde{W}_i = \frac{W_i e^{-\lambda R(X_i)}}{\sum_{r=1}^{N} W_r e^{-\lambda R(X_r)}}$$

e stimiamo

$$\widehat{p}_\lambda(E) = \sum_{i=1}^{N} \widetilde{W}_i \mathbf{1}_E(X_i).$$

Con J popolazioni indipendenti e pesi uniformi,

$$\widehat{p}(E) = \frac{1}{J} \sum_{j=1}^{J} \widehat{p}_{\lambda_j}(E).$$

Conclusione

L'SMC e' corretto perche' opera sulla probabilita' congiunta della *traiettoria*, usa il kernel originale come proposta e applica potenziali che telescopano fino a $e^{\lambda R(X_T)}$. Non calcola la probabilita' puntuale $p_0(x_T)$ di una completion, e non ne ha bisogno. Per un numero finito di particelle, lo stimatore self-normalized non e' esattamente unbiased; e' consistente e la sua affidabilita' dipende dalla non degenerazione dei pesi corretti.